DESENVOLVIMENTO DE UM MODELO DE APREDIZADO DE MÁQUINA PARA AVALIAÇÃO E OTIMIZAÇÃO DO CONSUMO ENERGÉTICO

PEDRO AFONSO CAVALCANTI SALVADOR1, PEDRO LEITE DE OLIVEIRA2, MANOEL HENRIQUE DA NÓBREGA MARINHO3

[1]Estudante de Engenharia da Computação, UPE, Recife-PE, pacs@poli.br;
[2]Estudante de Engenharia da Computação, UPE, Recife-PE, plo@poli.br;
[3]Professor Orientador da UPE, UPE, Recife-PE, marinho75@poli.br;

RESUMO: Este trabalho avalia a otimização do consumo energético no setor industrial siderúrgico utilizando técnicas de Aprendizado de Máquina. A pesquisa unifica bases de dados operacionais da indústria, parâmetros meteorológicos e a intensidade de carbono da rede elétrica. Aplicou-se o algoritmo preditivo *Random Forest Regressor* para prever a demanda de energia com 60 minutos de antecedência e identificar os fatores que mais impactam o sistema. Os resultados demonstram que o consumo vai além do acionamento de máquinas, dependendo fortemente do histórico recente de uso, do regime de carga e das condições climáticas. Conclui-se que o uso de modelos preditivos multivariáveis é essencial para guiar o gerenciamento dinâmico da operação, mitigar a pegada de carbono e fortalecer a eficiência energética industrial.

PALAVRAS-CHAVE: Eficiência Energética; Siderurgia; Aprendizado de Máquina; Previsão de Demanda; Sustentabilidade.

DEVELOPMENT OF A MACHINE LEARNING MODEL FOR ENERGY CONSUMPTION EVALUATION AND OPTIMIZATION

ABSTRACT: This study evaluates energy consumption optimization in the steel industry sector using Machine Learning techniques. The research unifies industrial operational databases, meteorological parameters, and grid carbon intensity data. The predictive algorithm Random Forest Regressor was applied to forecast energy demand 60 minutes in advance and identify the factors that most impact the system. The results demonstrate that energy consumption goes beyond machinery activation, depending heavily on recent usage history, load regime, and weather conditions. It is concluded that the use of multivariate predictive models is essential to guide dynamic operation management, mitigate the carbon footprint, and strengthen industrial energy efficiency.

KEYWORDS: Energy Efficiency; Steel Industry; Machine Learning; Demand Forecasting; Sustainability.

INTRODUÇÃO

O crescimento contínuo da demanda global por energia exige uma busca imediata por eficiência energética (Fulghum et al., 2026). No Brasil, embora haja forte expansão de fontes renováveis e uma das matrizes mais limpas do mundo, a transição energética plena ainda enfrenta obstáculos estruturais e burocráticos (Silva e Silva, 2025). Diante disso, é essencial encontrar soluções inovadoras que otimizem o uso dos recursos atuais, mitigando impactos ambientais e fortalecendo a resiliência do sistema elétrico.

Nesse cenário, o setor industrial, especialmente a siderurgia, ganha destaque (Landim, Silva e Tavares, 2017). Caracterizada pelo uso intensivo de energia e em constante expansão no país, a indústria siderúrgica pressiona fortemente as redes de distribuição. Assim, modernizar a gestão energética do setor deixou de ser apenas uma tática de redução de custos e tornou-se uma necessidade estratégica de sobrevivência e competitividade.

Para enfrentar esses desafios, as tecnologias digitais e a Inteligência Artificial (IA) apresentam-se como os caminhos mais promissores. Estudos recentes comprovam o potencial revolucionário da IA na otimização energética por meio de redes neurais, aprendizado de máquina (Machine Learning) e sistemas preditivos, que são capazes de prever demandas, monitorar equipamentos em tempo real e identificar desperdícios sem perda de desempenho (Santos e Tateoki, 2024; Barbosa e Vieira, 2024; Moraes e Lacerda, 2025).

Alinhado a essas inovações, este projeto visa aplicar tais abordagens tecnológicas na área da siderurgia. O trabalho servirá como um estudo de caso aprofundado para comprovar a utilidade prática da IA na promoção de operações industriais mais eficientes, econômicas e ambientalmente responsáveis.

MATERIAL E MÉTODOS

A metodologia adotada neste neste estudo aborda a visão sistemática sobre o uso da IA para a otimização do consumo energético e avaliação da sustentabilidade no setor industrial siderúrgico, e contempla as seguintes fases:

Fase 1 - Levantamento e revisão sistemática da literatura: Análise de estudos fundamentais sobre o uso de Inteligência Artificial para eficiência energética, justificando a escolha algorítmica e evidenciando as pressões ambientais e de custos na indústria.

Fase 2 - Desenvolvimento e aplicação das ferramentas de IA e visão computacional: Implementação de um modelo de aprendizado de máquina supervisionado, baseado no algoritmo *Random Forest Regressor*, estruturado para prever a demanda futura de energia com 60 minutos de antecedência.

Fase 3 - Coleta e preparação dos dados e ferramentas: Integração de bases operacionais da siderúrgica, dados climáticos do NASA POWER e intensidade de carbono do Electricity Maps, seguida de pré-processamento, engenharia de atributos e normalização.

Fase 4 - Execução experimental e avaliação do desempenho: Treinamento do modelo e validação técnica por meio de métricas estatísticas, alcançando um coeficiente de determinação (R^2) de 0,7800 e um Erro Médio Absoluto (MAE) de apenas 5%.

Fase 5 - Complementaridade com a expertise humana: Utilização dos insights gerados pelo modelo (como a importância relativa de cada variável) para fornecer suporte eficaz à tomada de decisão e permitir o planejamento dinâmico da operação pelos gestores.

Fase 6 - Proposta de diretrizes para governança tecnológica: Recomendação estrutural para integrar o modelo preditivo a sistemas de gerenciamento de energia em tempo real (EMS) e dispositivos IoT, visando a automação e o remanejamento inteligente de cargas.

Fase 7 - Elaboração do relatório final e recomendações: Conclusão de que a gestão energética depende do contexto operacional, temporal e climático, com a recomendação de explorar arquiteturas de *Deep Learning* para ampliar o horizonte preditivo em trabalhos futuros.

RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados da aplicação da metodologia, contemplando a implementação do algoritmo preditivo Random Forest Regressor. Os dados operacionais da siderúrgica, parâmetros meteorológicos e métricas de emissão de carbono são analisados criticamente. A abordagem discute o desempenho preditivo do modelo, a importância de cada variável e os impactos da inteligência artificial na otimização da eficiência energética e sustentabilidade no setor industrial.

Caracterização dos dados de referência e ferramentas utilizadas

Nesta etapa, foram caracterizados os recursos computacionais e as bases de dados utilizadas na fase experimental. O estudo baseou-se exclusivamente em três conjuntos de domínio público: (i) dados

operacionais e de consumo energético de uma indústria siderúrgica (DAEWOO Steel Co. Ltd, referente ao ano de 2018); (ii) registros de intensidade de carbono da rede elétrica obtidos via API do Electricity Maps; e (iii) variáveis meteorológicas locais (como temperatura, radiação solar e umidade) extraídas da plataforma NASA POWER. Todas as informações foram integradas em intervalos de 15 minutos, pré-processadas e normalizadas para alimentar o algoritmo preditivo Random Forest Regressor, garantindo a consistência da análise e evitando o vazamento de dados (data leakage). Também foram utilizadas ferramentas de inteligência artificial exclusivamente para auxiliar na revisão gramatical e na formatação do texto, sem interferir no conteúdo desenvolvido pelo autor.

Pré-processamento de dados (realizado na aplicação)

O pré-processamento transformou as diferentes fontes em uma base única e consistente. As datas foram padronizadas para o formato *datetime* e os conjuntos de dados cruzados via carimbo de tempo, ajustando a granularidade meteorológica para intervalos de 15 minutos. Variáveis instantâneas originais foram removidas para evitar o vazamento de dados (*data leakage*). Por fim, realizou-se a engenharia de atributos (com mapeamento binário, ordinal e *One-Hot Encoding*) para as variáveis categóricas, e a normalização dos dados contínuos através do método *MinMaxScaler*.

Ferramentas computacionais e bibliotecas

O desenvolvimento do modelo e o pré-processamento dos dados foram realizados utilizando a linguagem Python. Para a implementação, utilizaram-se as seguintes bibliotecas principais: pandas para a manipulação, cruzamento e estruturação da base de dados; numpy para o suporte a operações numéricas; scikit-learn (sklearn) para a divisão dos conjuntos de treino e teste, aplicação do algoritmo preditivo Random Forest Regressor e extração das métricas de avaliação estatística (MAE, MSE e R^2); além da biblioteca nativa os para interações com o sistema e gerenciamento de arquivos. Esse ambiente computacional permitiu o processamento dos dados e o treinamento robusto do modelo de aprendizado de máquina, formando a base experimental para os resultados analisados.

Execução da aplicação (Input) – Fase 1

Para prever o consumo futuro de energia (Usage_kWh), o modelo processou variáveis operacionais, climáticas, temporais e de intensidade de carbono. Para auxiliar nessa tarefa, foi criada a coluna atrasada Usage_kWh_60min_atras, que registra o consumo ocorrido exatamente 60 minutos antes.

A decisão de estabelecer esse horizonte preditivo de 60 minutos serviu para capturar a forte tendência de continuidade de funcionamento dos equipamentos pesados. A granularidade de 15 minutos original dos dados foi mantida, pois esse intervalo é crucial para monitorar variações sutis no maquinário siderúrgico.

Resultados Obtidos – Fase 2

A avaliação do modelo Random Forest Regressor demonstrou um excelente desempenho na captura dos padrões da fábrica. Conforme apresentado na Tabela 1 do artigo, as métricas alcançadas foram:

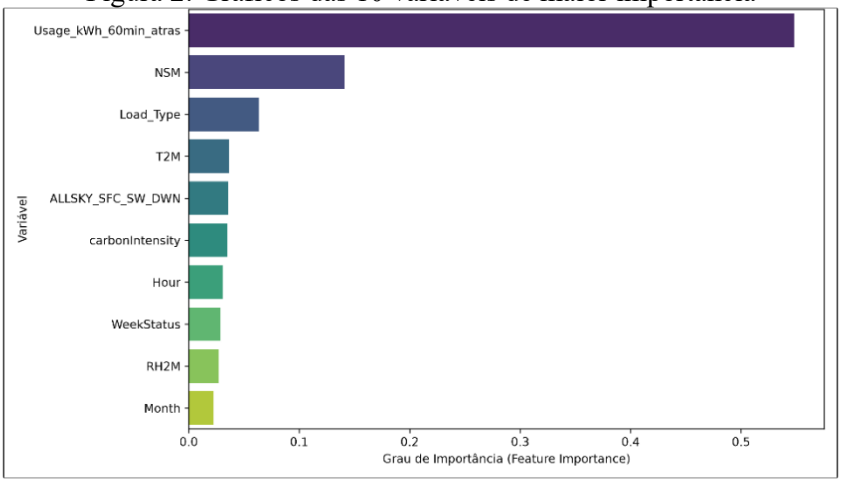
Tabela 1: Métricas de Avaliação

Métrica	Valor
Coeficiente de Determinação (R^2)	78,00%
Erro Médio Absoluto (MAE)	5,01%
Raiz do Erro Quadrático Médio (RMSE)	9,36%

Fonte: Elaborado pelos Autores, 2026.

A análise de importância das variáveis revelou que a variável Usage_kWh_60min_atras possui o maior peso explicativo, com 54,79% de importância. Na sequência, destacaram-se o indicador temporal NSM (14,11%) e o regime de trabalho Load_Type (6,35%). Porém, todas as variáveis foram utilizadas pelo modelo, mostrando a qualidade da base criada.

Figura 2: Gráficos das 10 variáveis de maior importância



Fonte: Elaborado pelos Autores, 2026.

Discussão dos Dados – Fase 3

O ajuste obtido de R^2=0,7800 evidencia a robusta capacidade da inteligência artificial em correlacionar os múltiplos fatores não lineares que regem a operação industrial. O MAE de 0,0501 corresponde a uma taxa de erro de apenas 5% em relação à escala normalizada, atestando alta precisão preditiva.

A predominância isolada da variável atrasada de 60 minutos comprova fisicamente que o consumo possui alta dependência temporal, pois equipamentos de grande porte mantêm seu estado operacional por longas horas. Ademais, as variáveis meteorológicas e os dados de calendário provaram ser essenciais para ajustar as predições ao estresse térmico da planta e às reduções de turno.

CONCLUSÃO

O estudo comprovou que o aprendizado de máquina, destacando-se o algoritmo *Random Forest Regressor,* é viável e eficaz para prever o consumo de energia siderúrgica com 60 minutos de antecedência. A construção de uma base de dados multidimensional, unindo parâmetros operacionais, meteorológicos e de carbono, evitou o vazamento de dados e forneceu suporte confiável à tomada de decisão.

Com as previsões, os gestores podem planejar dinamicamente a operação, remanejando cargas em horários de pico ou de alta emissão. Conclui-se, assim, que a eficiência energética é um processo complexo que depende do contexto operacional, climático e temporal, sendo esse processo possivelmente facilitado com o suporte de ferramentas baseadas em inteligência artificial.

REFERÊNCIAS

BARBOSA, Gustavo Inácio Pinto; VIEIRA, Henrique Teixeira. **Inteligência Artificial e Eficiência Energética: Oportunidades e Desenvolvimento. [S. l.: s. n.], 2024.da comunicação estratégica do tribunal de justiça de Pernambuco**. 53 fl. Relatório técnico (Mestrado) - Universidade Católica de Pernambuco. Programa de Pós-graduação em Indústrias Criativas. Mestrado Profissional em Indústrias Criativas, Recife, 2024.

FULGHUM, N. et al. **Global Electricity Review 2026**. [S. l.]: Ember, 2026.

LANDIM, Paula Martins; SILVA, Ana Carolina; TAVARES, Murilo. **Sustentabilidade da siderurgia brasileira: eficiência energética, emissões e competitividade**. Rio de Janeiro: Banco Nacional de Desenvolvimento Econômico e Social (BNDES), 2017.

MORAES, Harley Ferreira de; LACERDA, Paulo Sérgio Pádua de. **Integração de Inteligência Artificial para a Otimização do Consumo de Energia em Estabelecimentos Comerciais Visando Sustentabilidade Urbana**. Plural – Revista Acadêmica, v. 4, n. 8, nov. 2025.

SANTOS, Vinicius de Souza; TATEOKI, Getúlio Teruo. **Inteligência Artificial Aplicada à Otimização de Consumo Energético: Uma Revisão Sistemática de Técnicas e Aplicações**. In: CONGRESSO DE INOVAÇÃO, CIÊNCIA E TECNOLOGIA DO IFSP (15º CONICT), 15., 2024, São Paulo. Anais [...]. São Paulo: Instituto Federal de São Paulo, 2024.

SILVA, Christian Gianelli da; SILVA, Waner Wodson Aparecido Gonçalves. **O crescimento das energias renováveis no Brasil aos olhares globais: uma revisão sistemática sobre tendências, desafios e oportunidades**. Brazilian Journal of Production Engineering (BJPE), v. 11, n. 3, p. 23–33, 2025. DOI: 10.47456/bjpe.v11i3.48352.